

Aula 7 – Mineração de Dados

Classificação - Parte 2

Profa. Elaine Faria

UFU

Classificadores Bayesianos

- São classificadores estatísticos que classificam um objeto numa determinada classe baseando-se na probabilidade deste objeto pertencer a esta classe
- Naive Bayes
 - É um dos mais simples e bem difundidos algoritmos baseados no Teorema de Bayes
 - Supõe como hipótese de trabalho que o efeito do valor de um atributo não-classe é independente dos valores dos outros atributos
 - O valor de um atributo não influencia o valor dos outros

Ideia geral do Naive Bayes

- Consideramos um banco de dados de amostras classificadas em m classes distintas

$$C_1, C_2, \dots, C_m$$

- Suponha que X é uma tupla a ser classificada (não está no banco de dados de amostras)
- O classificador vai classificar X numa classe C para a qual a probabilidade condicional $P[C|X]$ é a mais alta possível
- Assim

$$P[C_i|X] > P[C_j|X]$$

para todas as outras classes C_j , $C_j \neq C_i$

A probabilidade $P[C_i|X]$ também é chamada **probabilidade posterior**

Probabilidade conjunta

- $P(X)$: probabilidade do evento X ocorrer
- $P(C)$: probabilidade do evento C ocorrer
- $P(X \& C)$: probabilidade de X e C ocorrerem
 - Se os eventos forem independentes: $P(X \& C) = P(X) * P(C) \rightarrow$ um evento não afeta a probabilidade de ocorrência do outro
 - Se os eventos não forem independentes: $P(X \& C) = P(X) * P(C|X)$
 - $P(C|X) = P(X \& C) / P(X) \rightarrow$ probabilidade de que C ocorra dado que X ocorreu

Teorema de Bayes

- Note que: $P(X \& C) = P(C \& X)$
- Logo: $P(C|X) * P(X) = P(X|C) * P(C)$
- Teorema de Bayes: $P(C|X) = P(X|C) * P(C) / P(X)$
- $P(X)$ é constante
- Maximizar $P(X|C) * P(C)$
- $P(X|C)$ é chamada de **probabilidade a priori**

Como calcular a probabilidade a priori?

- Suponha $X = (x_1, x_2, \dots, x_k)$ representa o evento conjunto $x_1 \cap x_2 \cap \dots \cap x_k$. Logo

$$P[X|C] = P[x_1 \cap x_2 \cap \dots \cap x_k|C]$$

Supondo a independência dos atributos, temos:

$$P[X|C] = P[x_1|C] * P[x_2|C] * \dots * P[x_n|C]$$

$P[x_i|C]$ pode ser calculada a partir da base de dados rotulada

Como calcular a probabilidade a priori?

- **Se o atributo A_i é categórico**

$$P[x_i|C] = \frac{\text{nro de tuplas classificadas em } C \text{ com atributo } A_i = x_i}{\text{nro de tuplas classificadas em } C}$$

- **Se o atributo A_i é contínuo**

$$P[x_i|C] = g(x_i, \mu_c, \sigma_c)$$

função de distribuição gaussiana onde μ é a média e σ é o desvio padrão

$$g(x_i, \mu_c, \sigma_c) = \frac{1}{\sqrt{2\pi} * \sigma_c} e^{-\frac{(x_i - \mu_c)^2}{2\sigma_c^2}}$$

Exemplo

Dada a instância de Teste:

$X = (\text{Refund} = \text{No}, \text{Divorced}, \text{Income} = 120\text{K})$

<i>Tid</i>	Refund	Marital Status	Taxable Income	Evade
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

- Precisamos estimar

$P(\text{Evade} = \text{Yes} \mid X)$ and $P(\text{Evade} = \text{No} \mid X)$

Vamos substituir

Evade = Yes por Yes, e

Evade = No por No

Exemplo

Dada a instância de Teste:

$X = (\text{Refund} = \text{No}, \text{Divorced}, \text{Income} = 120\text{K})$

<i>Tid</i>	Refund	Marital Status	Taxable Income	Evade
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

- Usando o teorema de Bayes

$$P(\text{Yes} | X) = \frac{P(X | \text{Yes})P(\text{Yes})}{P(X)}$$

$$P(\text{No} | X) = \frac{P(X | \text{No})P(\text{No})}{P(X)}$$

Como estimar $P(X|\text{Yes})$ e $P(X|\text{No})$?

Exemplo

Dada a instância de Teste:

$X = (\text{Refund} = \text{No}, \text{Divorced}, \text{Income} = 120\text{K})$

<i>Tid</i>	Refund	Marital Status	Taxable Income	Evade
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

$P(X \mid \text{Yes}) =$

$P(\text{Refund} = \text{No} \mid \text{Yes}) \times$

$P(\text{Divorced} \mid \text{Yes}) \times$

$P(\text{Income} = 120\text{K} \mid \text{Yes})$

$P(X \mid \text{No}) =$

$P(\text{Refund} = \text{No} \mid \text{No}) \times$

$P(\text{Divorced} \mid \text{No}) \times$

$P(\text{Income} = 120\text{K} \mid \text{No})$

Exemplo

Tid	Refund	Marital Status	Taxable Income	Evade
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

- $P(y)$ = fração de instâncias da classe Y

$$P(\text{No}) = 7/10,$$

$$P(\text{Yes}) = 3/10$$

- Atributos Categóricos - Exemplo

$$P(\text{Status}=\text{Married} | \text{No}) = 4/7$$

$$P(\text{Refund}=\text{Yes} | \text{Yes})=0$$

- Atributos Contínuos - Exemplo

Para (Income, Classe=No):

Se Classe=No

◆ média = 110

◆ desvio padrão = 2975

$$P(\text{Income} = 120 | \text{No}) = \frac{1}{\sqrt{2\pi(54.54)}} e^{-\frac{(120-110)^2}{2(2975)}} = 0.0072$$

Exemplo

Dada a instância de teste: $X = (\text{Refund} = \text{No}, \text{Divorced}, \text{Income} = 120\text{K})$

Naïve Bayes Classifier:

$$P(\text{Refund} = \text{Yes} \mid \text{No}) = 3/7$$

$$P(\text{Refund} = \text{No} \mid \text{No}) = 4/7$$

$$P(\text{Refund} = \text{Yes} \mid \text{Yes}) = 0$$

$$P(\text{Refund} = \text{No} \mid \text{Yes}) = 1$$

$$P(\text{Marital Status} = \text{Single} \mid \text{No}) = 2/7$$

$$P(\text{Marital Status} = \text{Divorced} \mid \text{No}) = 1/7$$

$$P(\text{Marital Status} = \text{Married} \mid \text{No}) = 4/7$$

$$P(\text{Marital Status} = \text{Single} \mid \text{Yes}) = 2/3$$

$$P(\text{Marital Status} = \text{Divorced} \mid \text{Yes}) = 1/3$$

$$P(\text{Marital Status} = \text{Married} \mid \text{Yes}) = 0$$

For Taxable Income:

If class = No: sample mean = 110

sample variance = 2975

If class = Yes: sample mean = 90

sample variance = 25

- $$\begin{aligned} P(X \mid \text{No}) &= P(\text{Refund}=\text{No} \mid \text{No}) \\ &\quad \times P(\text{Divorced} \mid \text{No}) \\ &\quad \times P(\text{Income}=120\text{K} \mid \text{No}) \\ &= 4/7 \times 1/7 \times 0.0072 = 0.0006 \end{aligned}$$
- $$\begin{aligned} P(X \mid \text{Yes}) &= P(\text{Refund}=\text{No} \mid \text{Yes}) \\ &\quad \times P(\text{Divorced} \mid \text{Yes}) \\ &\quad \times P(\text{Income}=120\text{K} \mid \text{Yes}) \\ &= 1 \times 1/3 \times 1.2 \times 10^{-9} = 4 \times 10^{-10} \end{aligned}$$

Since $P(X|\text{No})P(\text{No}) > P(X|\text{Yes})P(\text{Yes})$

Therefore $P(\text{No}|X) > P(\text{Yes}|X)$

=> Classe = No

Problema da Frequência Zero

- O que acontece se um determinado valor de atributo não aparece na base de treinamento, mas aparece no exemplo de teste?

Problema da Frequência Zero

Considere que o Tid = 7 foi deletado

Tid	Refund	Marital Status	Taxable Income	Evade
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Classificador Naïve Bayes

$$P(\text{Refund} = \text{Yes} \mid \text{No}) = 2/6$$

$$P(\text{Refund} = \text{No} \mid \text{No}) = 4/6$$

$$\rightarrow P(\text{Refund} = \text{Yes} \mid \text{Yes}) = 0$$

$$P(\text{Refund} = \text{No} \mid \text{Yes}) = 1$$

$$P(\text{Marital Status} = \text{Single} \mid \text{No}) = 2/6$$

$$\rightarrow P(\text{Marital Status} = \text{Divorced} \mid \text{No}) = 0$$

$$P(\text{Marital Status} = \text{Married} \mid \text{No}) = 4/6$$

$$P(\text{Marital Status} = \text{Single} \mid \text{Yes}) = 2/3$$

$$P(\text{Marital Status} = \text{Divorced} \mid \text{Yes}) = 1/3$$

$$P(\text{Marital Status} = \text{Married} \mid \text{Yes}) = 0/3$$

For Taxable Income:

If class = No: sample mean = 91

sample variance = 685

If class = No: sample mean = 90

sample variance = 25

Dado $X = (\text{Refund} = \text{Yes}, \text{Divorced}, 120K)$

$$P(X \mid \text{No}) = 2/6 \times 0 \times 0.0083 = 0$$

$$P(X \mid \text{Yes}) = 0 \times 1/3 \times 1.2 \times 10^{-9} = 0$$

Naïve Bayes não será capaz de
classificar X em Yes ou No!

Problema da Frequência Zero

- Se uma das probabilidades condicionais é zero, então a expressão inteira torna-se zero
 - É preciso usar outras estimativas de probabilidade condicional

- **Estimativa de probabilidade:**

Original: $P(X_i = c|y) = \frac{n_c}{n}$

Estimativa de Laplace: $P(X_i = c|y) = \frac{n_c + 1}{n + v}$

Estimativa M: $P(X_i = c|y) = \frac{n_c + mp}{n + m}$

n : número de instâncias de treinamento que pertencem à classe y

n_c : número de instâncias com $X_i = c$ and $Y = y$

v : número total de valores do atributo que X_i pode assumir

p : estimativa inicial de $(P(X_i = c|y))$ conhecida a priori

m : hiper-parâmetro para o nível de confiança em p

Valores Ausentes


- Treinamento
 - Excluir exemplo do conjunto de treinamento
- Classificação
 - Considerar apenas os demais atributos

Naive Bayes - Resumo

- Robusto a ruídos isolados
- Lida com valores ausentes, ignorando a instância durante os cálculos de estimativa de probabilidade
- Robusto a atributos irrelevantes
- Atributos redundantes e correlacionados podem violar a suposição condicional de classe
 - É possível usar outras técnicas, como Bayesian Belief Networks (BBN)


Redes Bayesianas

- É comum existir dependência entre os atributos.
 - Neste caso, pode-se utilizar uma Rede Bayseana de Crença
- Rede Bayesiana de Crença é uma estrutura com duas componentes
 - Um grafo dirigido acíclico onde
 - Cada vértice representa um atributo
 - Os arcos ligando os vértices representam uma dependência entre estes atributos
 - Tabela de Probabilidade Condicional (CPT) para cada atributo Z
 - Associa cada nó ao seu pai




Redes Bayesianas

- Suposição do Naive Bayes



Redes Bayesianas

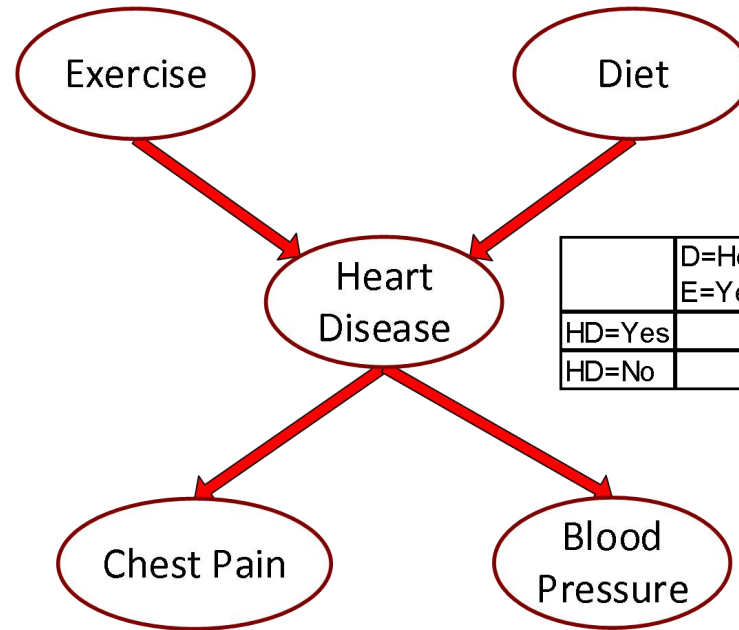
- Se X não tem pai, a tabela contém a probabilidade a priori $P(X)$
- Se X tem somente um nó pai (Y), a tabela contém a probabilidade condicional $P(X|Y)$
- Se X tem múltiplos nó pai (Y_1, Y_2, \dots, Y_k), a tabela contém a probabilidade condicional $P(X|Y_1, Y_2, \dots, Y_k)$



Redes Bayesianas - Exemplo

Exercise=Yes	0.7
Exercise=No	0.3

Diet=Healthy	0.25
Diet=Unhealthy	0.75



	D=Healthy E=Yes	D=Healthy E=No	D=Unhealthy E=Yes	D=Unhealthy E=No
HD=Yes	0.25	0.45	0.55	0.75
HD=No	0.75	0.55	0.45	0.25

	HD=Yes	HD=No
CP=Yes	0.8	0.01
CP=No	0.2	0.99

	HD=Yes	HD=No
BP=High	0.85	0.2
BP=Low	0.15	0.8

Redes Bayesianas - Exemplo

- Dado: $X = (E=\text{No}, D=\text{Yes}, CP=\text{Yes}, BP=\text{High})$

- Calcular $P(HD|E,D,CP,BP)$?

- $P(HD=\text{Yes} | E=\text{No}, D=\text{Yes}) = 0.55$

$$P(CP=\text{Yes} | HD=\text{Yes}) = 0.8$$

$$P(BP=\text{High} | HD=\text{Yes}) = 0.85$$

- $P(HD=\text{Yes} | E=\text{No}, D=\text{Yes}, CP=\text{Yes}, BP=\text{High})$

$$\propto 0.55 \times 0.8 \times 0.85 = 0.374$$

- $P(HD=\text{No} | E=\text{No}, D=\text{Yes}) = 0.45$

$$P(CP=\text{Yes} | HD=\text{No}) = 0.01$$

$$P(BP=\text{High} | HD=\text{No}) = 0.2$$

- $P(HD=\text{No} | E=\text{No}, D=\text{Yes}, CP=\text{Yes}, BP=\text{High})$

$$\propto 0.45 \times 0.01 \times 0.2 = 0.0009$$

**Classifica
X como
Yes**

Referências

- Katti, F.; Lorena, A. C.; Gama, J.; Carvalho, A. C. P. L. F. Inteligência Artificial: Uma abordagem de Aprendizado de Máquina, LTC, 2011
- Tan P., SteinBack M. e Kumar V. Introduction to Data Mining, Pearson, 2006